Localizzazione
Template matching

Annalisa Franco
annalisa.franco@unibo.it

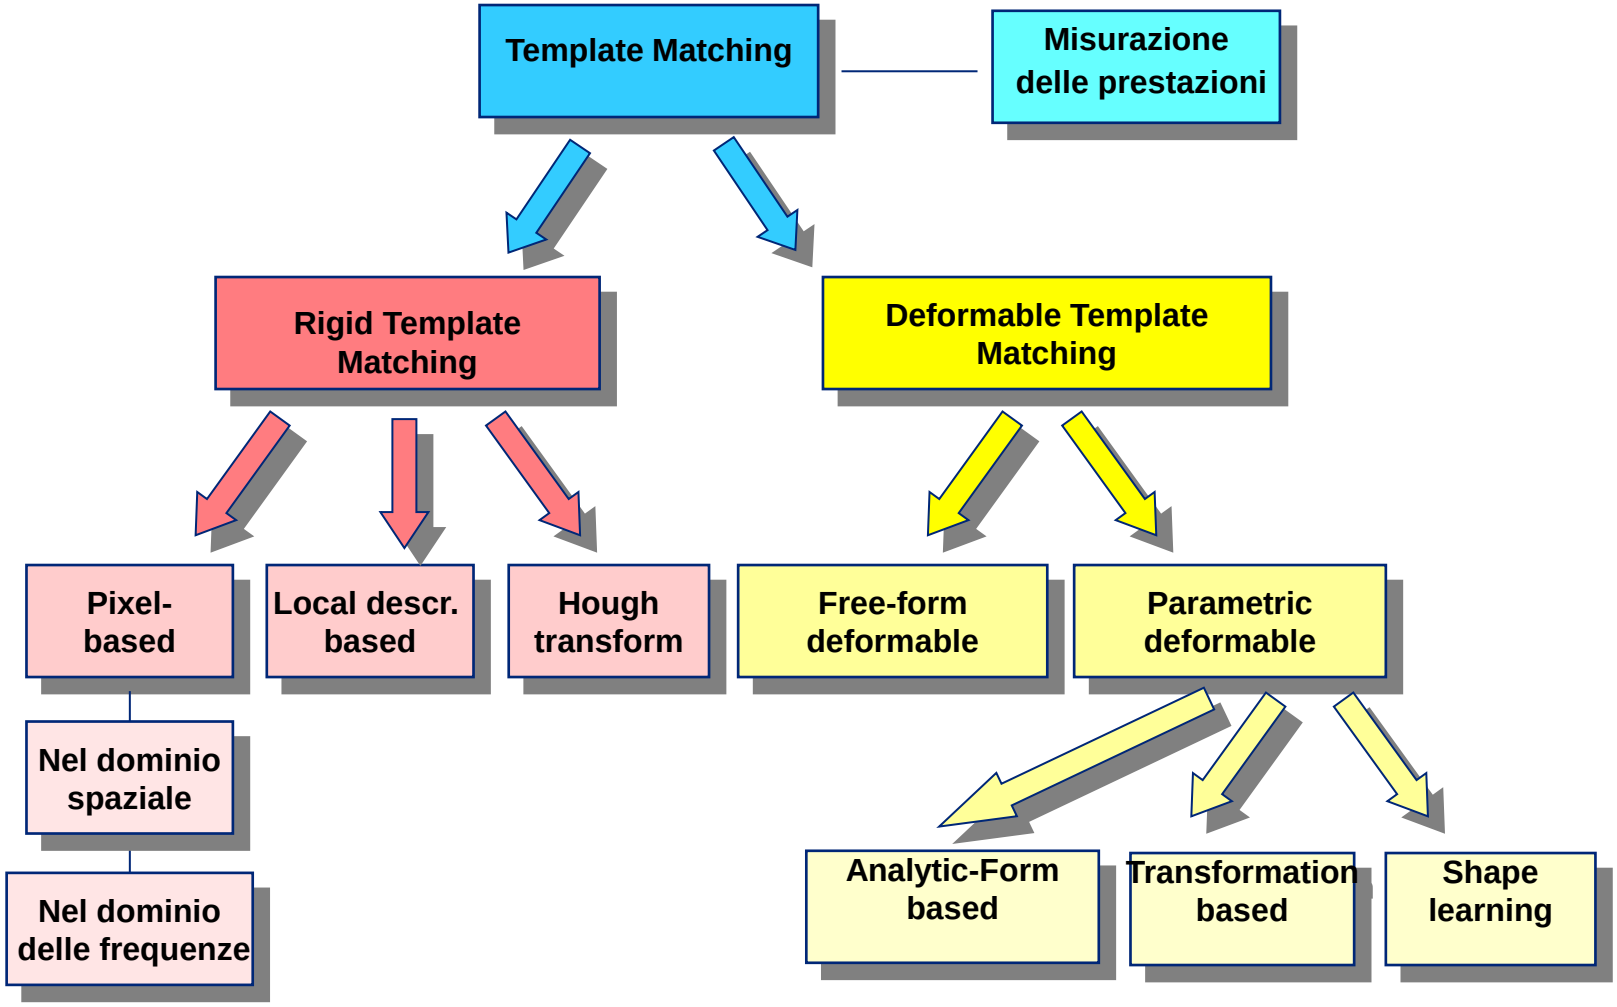
Tecniche di localizzazione

Il termine ***template matching*** è molto generico nell'ambito del PR, ma normalmente fa riferimento alla "ricerca" di un template **T** all'interno di un'immagine **I** con l'obiettivo di determinare se **I** contiene l'oggetto (*match*) e in quale posizione **T** appare nell'immagine.





Template matching



Prestazioni di localizzazione

In un sistema di *localizzazione di oggetti*, è necessario misurare:

- **False localizzazioni (false positive)**: percentuale di casi in cui il sistema localizza un oggetto non corretto.
- **Mancate localizzazioni (false negative)**: percentuale di casi in cui il sistema non localizza nessun oggetto, sebbene l'oggetto sia presente (questi errori sono detti anche drop o miss).
- **Precisione di localizzazione**: indica quanto precisamente in media gli oggetti sono localizzati (accuracy).

I principali indicatori sono:

Precision: frazione di oggetti localizzati che sono rilevanti: $P = \frac{TP}{TP+FP}$

Recall: frazione di oggetti rilevanti che sono stati localizzati: $R = \frac{TP}{TP+FN}$

TP → true positive, *FP* → false positive, *FN* → false negative

Valutare un sistema di localizzazione

- Come individuare TP, FP, FN?



- Dato un oggetto localizzato d_i e un oggetto del ground truth g_j lo score associato al matching tra i due può essere calcolato come

$$S(d_i, g_j) = \frac{\text{area}(d_i) \cap area(g_j)}{\text{area}(d_i) \cup area(g_j)}$$

- Può essere necessario utilizzare un *algoritmo di assegnamento* che ottimizzi le coppie (d_i, g_j) sulla base del relativo *score*.

Valutare un sistema di localizzazione

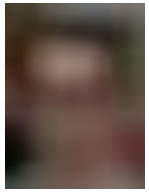
False e mancate localizzazioni sono spesso *legate tra loro* ed entrambe funzione di alcuni parametri di tolleranza del sistema:

- se si rende il sistema meno tollerante ai falsi in modo da evitare che vengano localizzati oggetti non esistenti, aumenta la probabilità di perdere anche qualche oggetto genuino.
- viceversa se si rende il sistema più tollerante in modo da localizzare tutti gli oggetti presenti (anche quelli “difficili”) allora aumenta la probabilità di localizzare anche qualche falso oggetto.
- i sistemi possono in genere essere regolati per operare a diversi livelli di tolleranza …

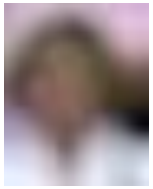




s = 0.95



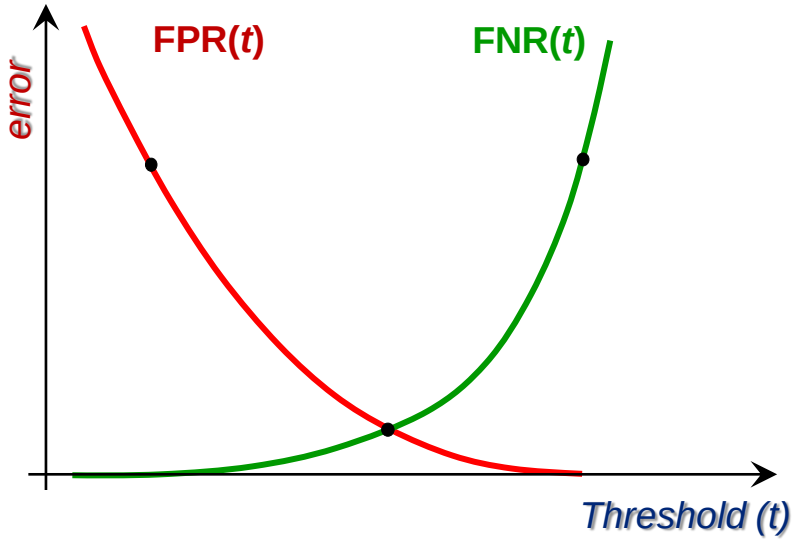
s = 0.55



s = 0.51

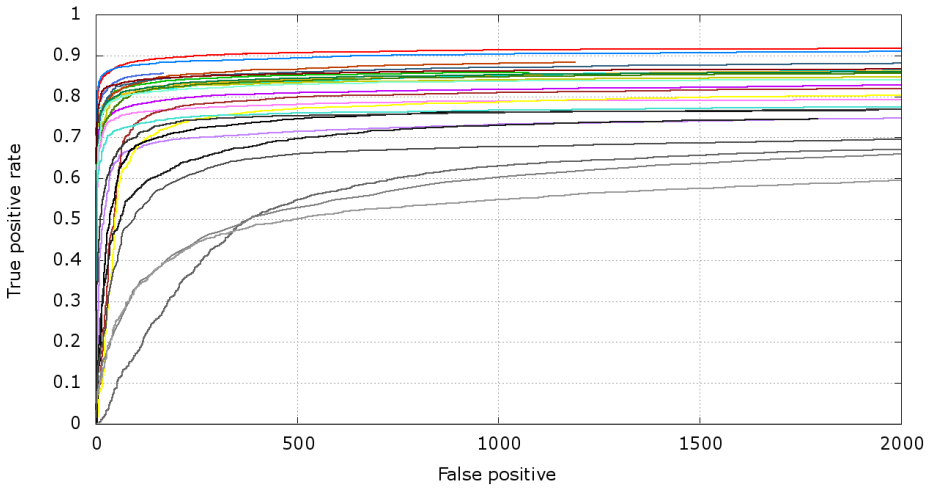
Valutare un sistema di localizzazione

Le prestazioni al variare della «tolleranza» possono essere sintetizzate in forma grafica:



Curva ROC

(**Receiver Operating Characteristic**)



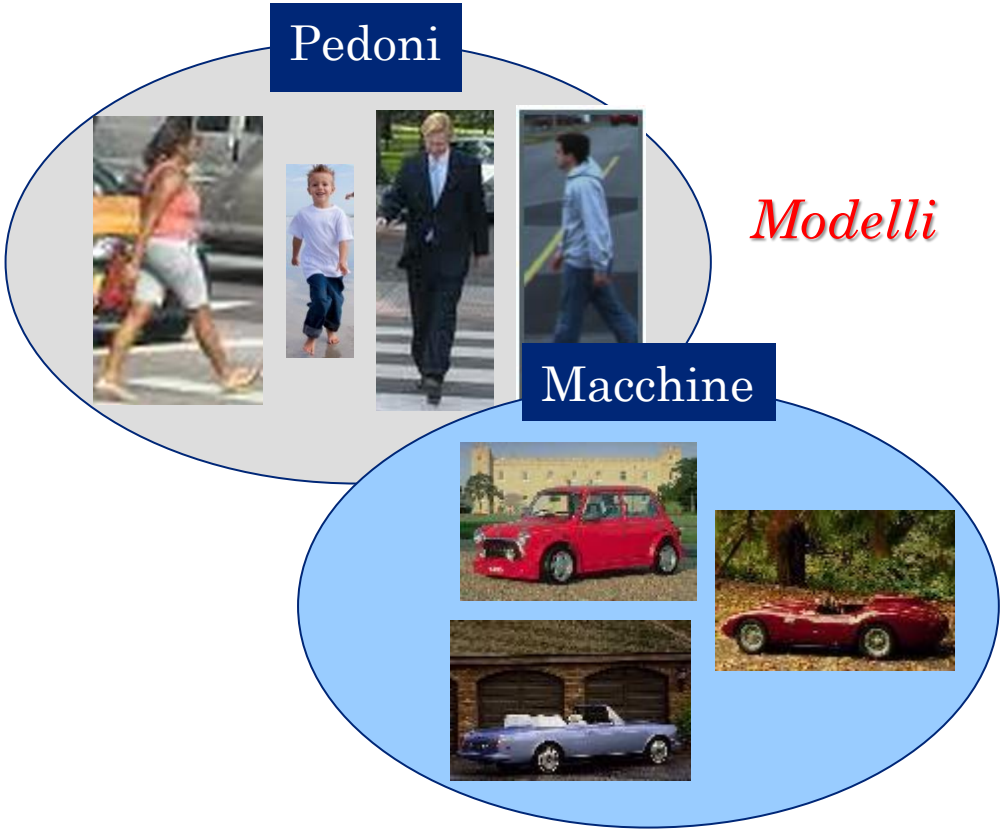
Template matching rigido basato su correlazione

Template matching "rigido"

Un approccio molto utilizzato per la localizzazione di oggetti si basa sull'analisi delle immagini con una finestra mobile che viene fatta scorrere sull'immagine e confrontata di volta in volta con i diversi template degli oggetti da ricercare.

Es. Ricercare tutti i pedoni e
le macchine presenti nella scena





Template matching "rigido"



Il template **T** è costituito da un oggetto **rigido** (normalmente una piccola immagine in formato raster).

- T viene sovrapposto a I in tutte le possibili posizioni (*rispetto agli assi X e Y*), ma a seconda dell'applicazione, può essere anche necessario *ruotarlo* e *scalarlo* (trasformazione AFFINE). Nel seguito denominiamo T_i le istanze di T ottenute dalle trasformazioni precedenti (spostamento in X e Y, rotazione, scala).
- Per ogni istanza T_i il grado di similarità viene solitamente calcolato massimizzando la *correlazione* con la porzione di immagine I "coperta" da T_i (che ha la stessa dimensione di T_i).
- Normalmente i template hanno dimensione inferiore all'immagine; *in caso contrario bisogna fare attenzione agli effetti di bordo!* La dimensione dei modelli può variare…







Template matching "rigido"

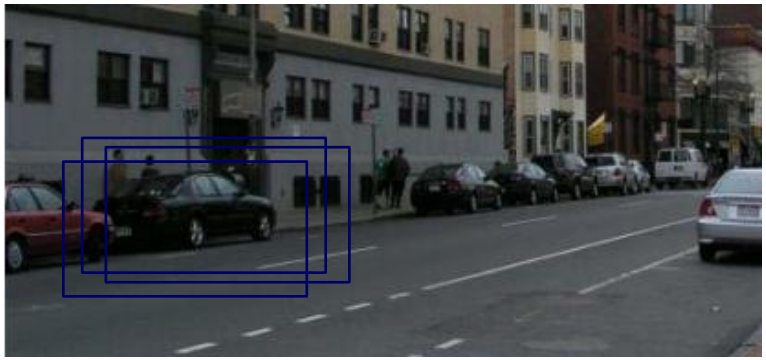
- Il confronto tra una sottoimmagine e un modello viene fatta sulla base di apposite feature (es. intensità, descrittori SIFT);
- Per decidere se un oggetto è presente nella scena è necessario imporre una soglia alla similarità (distanza) tra le feature della sottofinestra in esame e il modello;

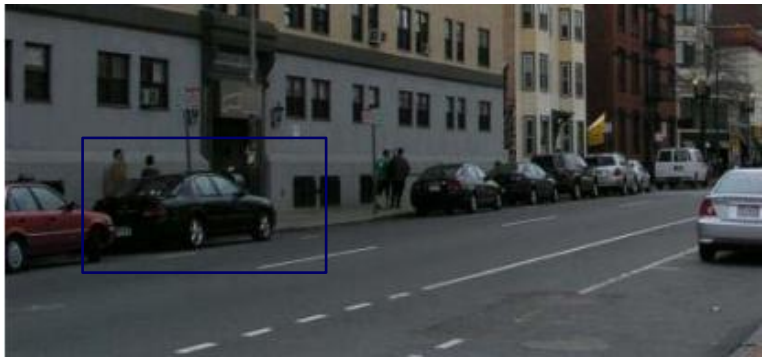


≈



- È possibile che lo stesso oggetto venga localizzato in più posizioni adiacenti; è necessaria quindi una fase di post-processing (es. fusione, soppressione dei non massimi).





Un po' di storia…Pixel-based template matching

Immagini e template sono, per semplicità di notazione, definiti nel seguito come vettori 1-dimensionali ottenuti postponendo le righe delle corrispondenti matrici 2-dimensionali.

Correlation based: Data un'immagine **I** e un'istanza $\mathbf{T}_i$, una misura intuitiva di diversità tra **I** e $\mathbf{T}_i$ è la *Sum of Squared Differences* (***SSD***):

$$SSD(\mathbf{I}, \mathbf{T}_i) = \|\mathbf{I} - \mathbf{T}_i\|^2 = (\mathbf{I} - \mathbf{T}_i)^{\mathrm{T}}(\mathbf{I} - \mathbf{T}_i) = \|\mathbf{I}\|^2 + \|\mathbf{T}_i\|^2 - 2\mathbf{T}_i{}^{\mathrm{T}}\mathbf{I}$$

quando i termini $\|I\|^2$ e $\|T_i\|^2$ sono costanti, minimizzare il primo termine corrispondere a massimizzare la *CrossCorrelation* (*CC*) tra **I** e $\mathbf{T}_i$:

$$CC(\mathbf{I}, \mathbf{T}_i) = \mathbf{T}_i{}^{\mathrm{T}}\,\mathbf{I} = \sum_k \mathbf{T}_i[k] \cdot \mathbf{I}[k]$$

In alcuni casi la Cross Correlation non è una misura robusta per il template matching e diventa necessario applicare alcune normalizzazioni. Ciò accade in particolare quando **I** e $\mathbf{T}_i$ non sono costanti (ad esempio):

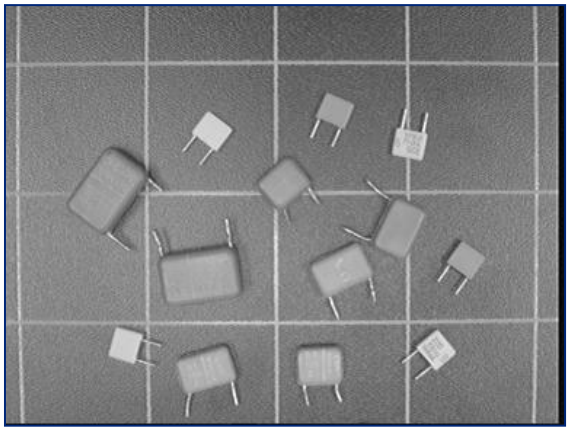
- Ricerca dello stesso template su immagini diverse.
- Istanze dello stesso template diverse tra loro per numero di pixel e luminosità media.

Correlation-based approach: problemi

- ***Complessità computazionale***
  - Il numero di operazioni richieste cresce linearmente con il numero di istanze e con il numero di pixel di I e T (e quindi in modo quadratico rispetto al lato di I e di T).
  - In pratica per applicazioni real-time l'approccio *base* è quasi sempre inapplicabile.

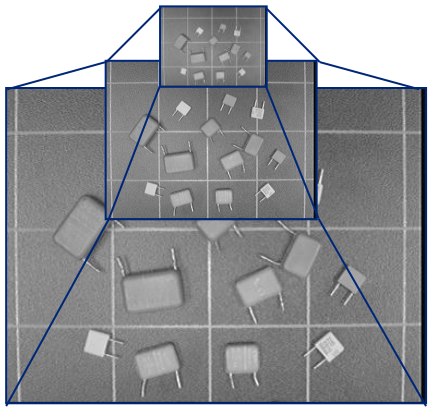
- ***Difficile gestione di pattern deformabili***

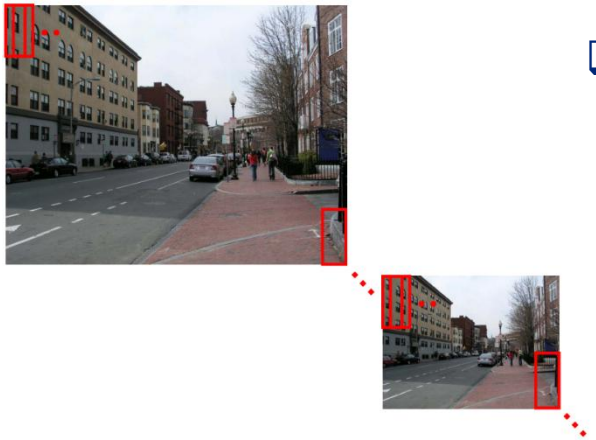
- Necessaria invarianza per posizione, rotazione, scala e aspect ratio (lunghezza/altezza). *Ciò implica un enorme numero di istanze !*
- Come gestire le variazioni di colore? (es: operare su edge e non su immagine intensità)
- Come gestire le deformazioni locali (ad esempio i piedini piegati o di diversa lunghezza)?



Evoluzioni: Approccio multirisoluzione

- Per ridurre la ***complessità computazionale*** si segue la ricerca su una gerarchia crescente di risoluzioni. Viene creata una piramide di risoluzioni ad esempio dimezzando la risoluzione ad ogni livello.
- La ricerca viene eseguita inizialmente sulla risoluzione più bassa, e ai livelli successivi vengono analizzate solo le *istanze promettenti* (la cui correlazione a livello inferiore eccedeva una certa soglia normalmente piuttosto bassa per evitare false reiezioni).
- Ciò consente di eseguire una scrematura ai livelli iniziali e di perfezionare la localizzazione e filtrare false accettazioni ai livelli successivi.



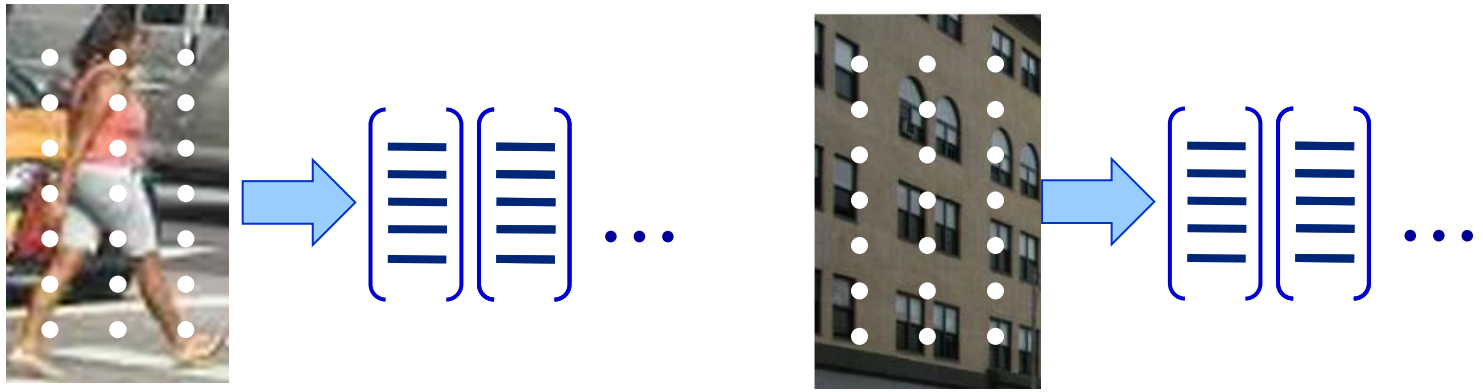


- L'approccio multirisoluzione viene usato anche per localizzare oggetti a scale diverse.

Template matching rigido basato su features

Feature per il template matching

- Per la rappresentazione dei template e delle singole patch è possibile usare dei descrittori locali (es. SIFT, SURF, HOG, Haar) associati a punti distribuiti uniformemente sull'immagine (*dense sampling*).



- Il confronto tra descrittori può essere effettuato sommando o mediando le distanze Euclidee calcolate tra descrittori di punti corrispondenti.
- Se la distanza ottenuta è inferiore alla soglia prefissata, l'oggetto si considera localizzato.

Esempio: localizzazione prodotti



La localizzazione del volto

Data una singola immagine o una sequenza video rilevare la presenza di uno o più volti e localizzarne la posizione all'interno dell'immagine.

È necessaria l'indipendenza rispetto a:

- posizione, orientazione, scala, espressione del volto;
- fattori esterni quali l'illuminazione o la presenza di uno sfondo complesso.







Localizzazione dei volti



- La localizzazione dei volti avviene analizzando sottofinestre consecutive (sovrapposte) dell'immagine in input e valutando per ciascuna se appartiene alla classe dei volti.
- Il localizzatore di Viola e Jones è uno dei più robusti ed efficienti allo stato dell'arte
  - **L'addestramento è molto lento (può richiedere giorni);**
  - **La procedura di localizzazione è molto efficiente** (funzionamento real-time).

Il localizzatore di Viola e Jones (1)

- La proposta di Paul Viola e Michael Jones, introdotta in generale per la localizzazione di oggetti, è stata applicata con successo all'individuazione di volti. Prevede di creare un **classificatore** che inizialmente è addestrato mediante multiple istanze della classe da individuare (*esempi positivi*), e varie istanze di *esempi negativi*, ovvero immagini che non contengono alcun oggetto della classe in esame.

- Durante il training sono estratte diverse caratteristiche dagli esempi e selezionate quelle che risultano particolarmente discriminanti. Questo tipo di informazione è racchiusa nei parametri del modello statistico.

- Se il classificatore addestrato non trova un oggetto che invece è presente (*miss*) oppure ne indica erroneamente la presenza (*false alarm*), si può ricalibrare il suo addestramento aggiungendo gli esempi corrispondenti (positivi o negativi) al training set.

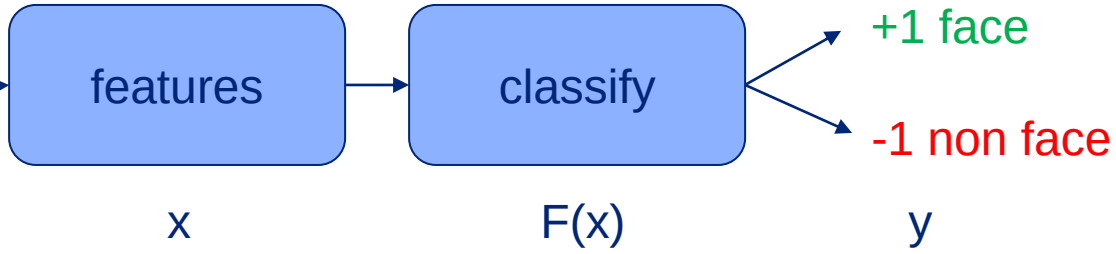
P. Viola, M. J. Jones, "Rapid Object Detection using a Boosted Cascade of Simple Features", in proc. IEEE International Conference on Computer Vision and Pattern Recognition, vol. 1, pp. 511-518, 2001.

Il localizzatore di Viola e Jones (3)

- Estrazione e valutazione di **Haar-like feature**
- Classificazione mediante **boosting** (costruzione di un classificatore robusto come combinazione di molteplici classificatori semplici)
- **Multiscale detection**

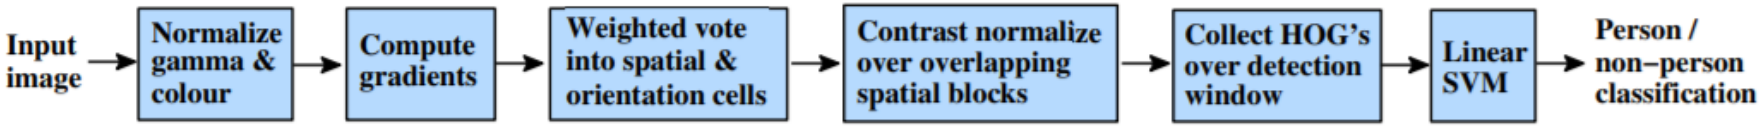




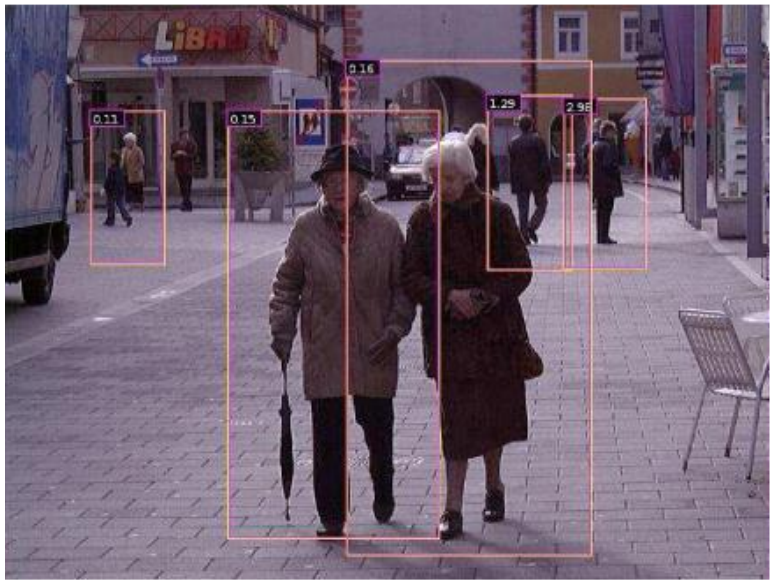


La localizzazione è effettuata facendo scorrere una finestra di ricerca (le cui dimensioni possono variare) sull'immagine, estraendo le feature presenti nella finestra e classificando la finestra come volto o non volto.

Histogram of Oriented Gradients (HoG)



- HoG è un descrittore molto noto, proposto per la localizzazione di persone.
- Si basa sull'utilizzo di una finestra mobile che viene applicata all'immagine in tutte le possibili posizioni e a diverse scale.
- Ciascuna finestra viene partizionata in sottoregioni e per ciascuna sottoregione viene calcolato un descrittore HoG (simile ai descrittori SIFT già visti).
- I descrittori delle sottofinestre vengono concatenati e il descrittore globale viene usato per la classificazione tramite SVM.
- Viene infine applicate una soppressione dei non massimi per semplificare l'output e ridurre il numero di falsi positivi.



Histogram of Oriented Gradients (HoG)

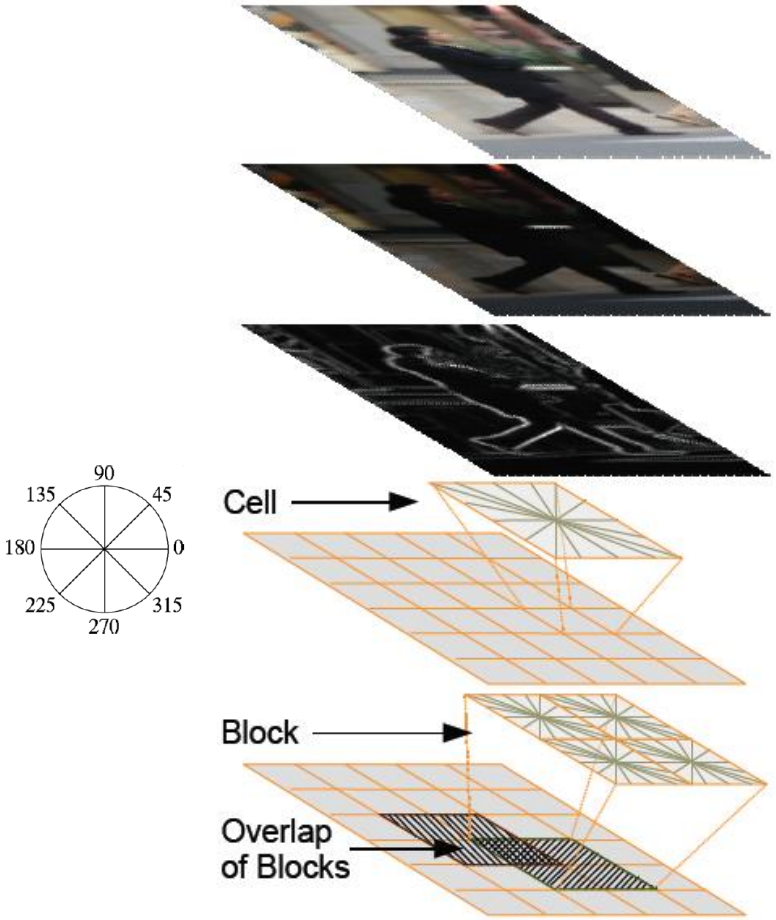
Immagine in input
(sottoregione riscalata a 64×128)

Normalizzazione colore

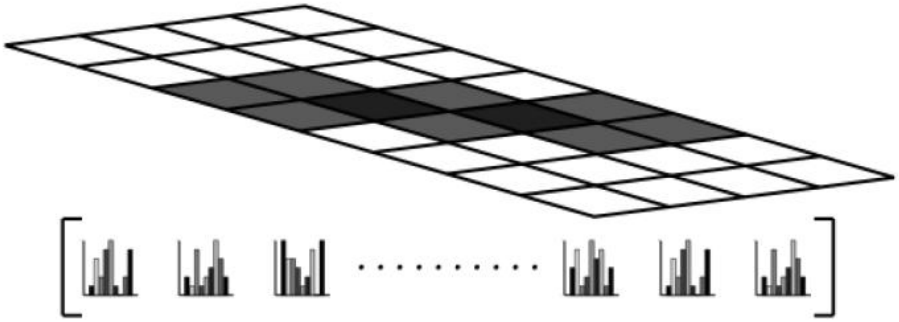
Calcolo gradiente

Calcolo istogramma per ciascuna cella
(celle 8×8 pixel ➔ 8×16 celle)

Normalizzazione degli istogrammi
nelle finestre con overlap
(celle 2×2 ➔ 7×15 blocchi)



Histogram of Oriented Gradients (HoG)



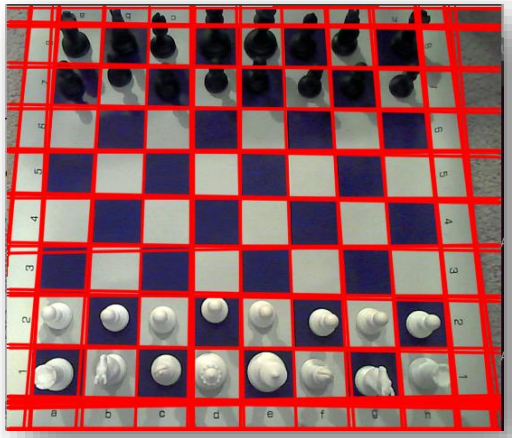


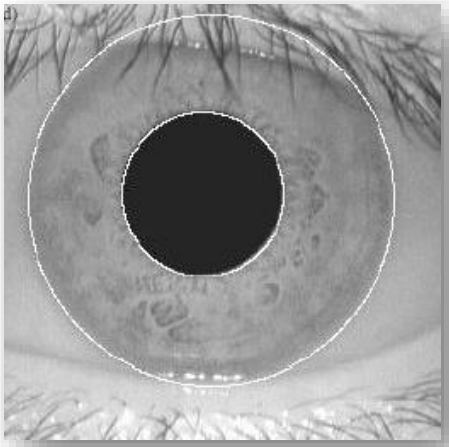




La trasformata di Hough

Parametric model fitting













Linea

$y = mx + c$

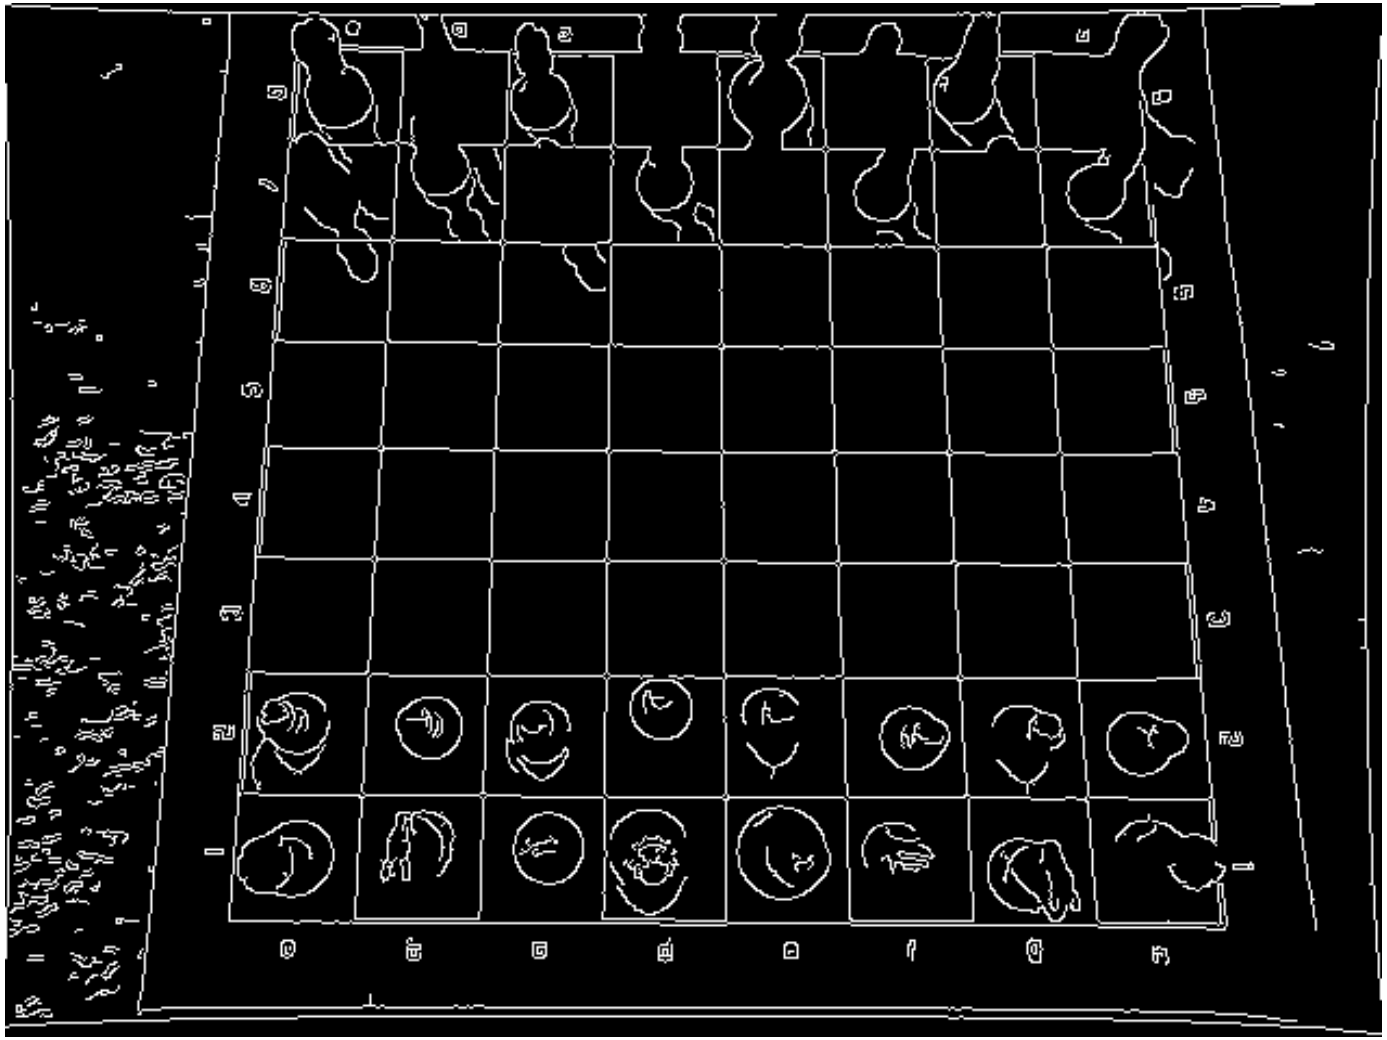
Cerchio

$r^2 = (x - x_c)^2 + (y - y_c)^2$

Ellisse

$\left(\frac{x-x_c}{a}\right)^2 + \left(\frac{y-y_c}{b}\right)^2 = 1$

Edge e modelli parametrici…



Trasformata di Hough

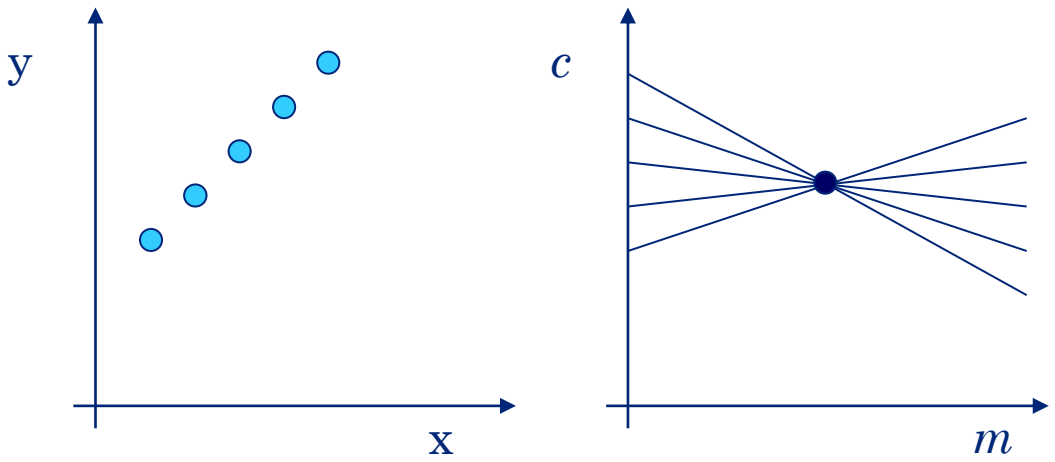
- Viene definito uno ***spazio di parametri*** in cui ogni punto è associabile a una soluzione del problema. Lo spazio viene discretizzato e gestito come una matrice multidimensionale (denominata *array di accumulatori*) le cui entry sono dette *celle*.
- Per eseguire la trasformata si esegue una scansione dell'immagine: ogni pixel ***vota*** per una o più celle dello spazio di parametri incrementandone la probabilità. Al termine della scansione le celle che hanno accumulato i valori più elevati indicano le soluzioni più probabili del problema.
- La *definizione dello spazio di parametri e dei meccanismi di voto* dipendono dal tipo di oggetto che si vuole identificare.

Sebbene la trasformata di Hough sia ritenuta da alcuni computazionalmente molto costosa, e quindi difficilmente utilizzabile in applicazioni run-time, attraverso: l'uso del gradiente, il calcolo in aritmetica intera, il pre-calcolo di valori e approcci multi-risoluzione possono essere ottenute implementazioni molto efficienti (più efficienti di correlazione).

Trasformata di Hough: *rette* (1)

- Ogni retta nel piano *x*, *y* può essere descritta dall'equazione:

$$y = m \cdot x + c$$



- Lo spazio dei parametri (*m*, *c*) viene discretizzato e codificato da un array bidimensionale **A**[m_1 m_2 ... m_r][c_1 c_2 ... c_s].

Trasformata di Hough: *rette* (2)

- Durante la scansione dell'immagine ogni pixel "attivo" (x, y) individua una retta nello spazio dei parametri: fissati x e y nell'equazione della retta, per ogni valore discreto di m_i, i=1..r si determina il corrispondente c_j e si incrementa A[m_i][c_j].

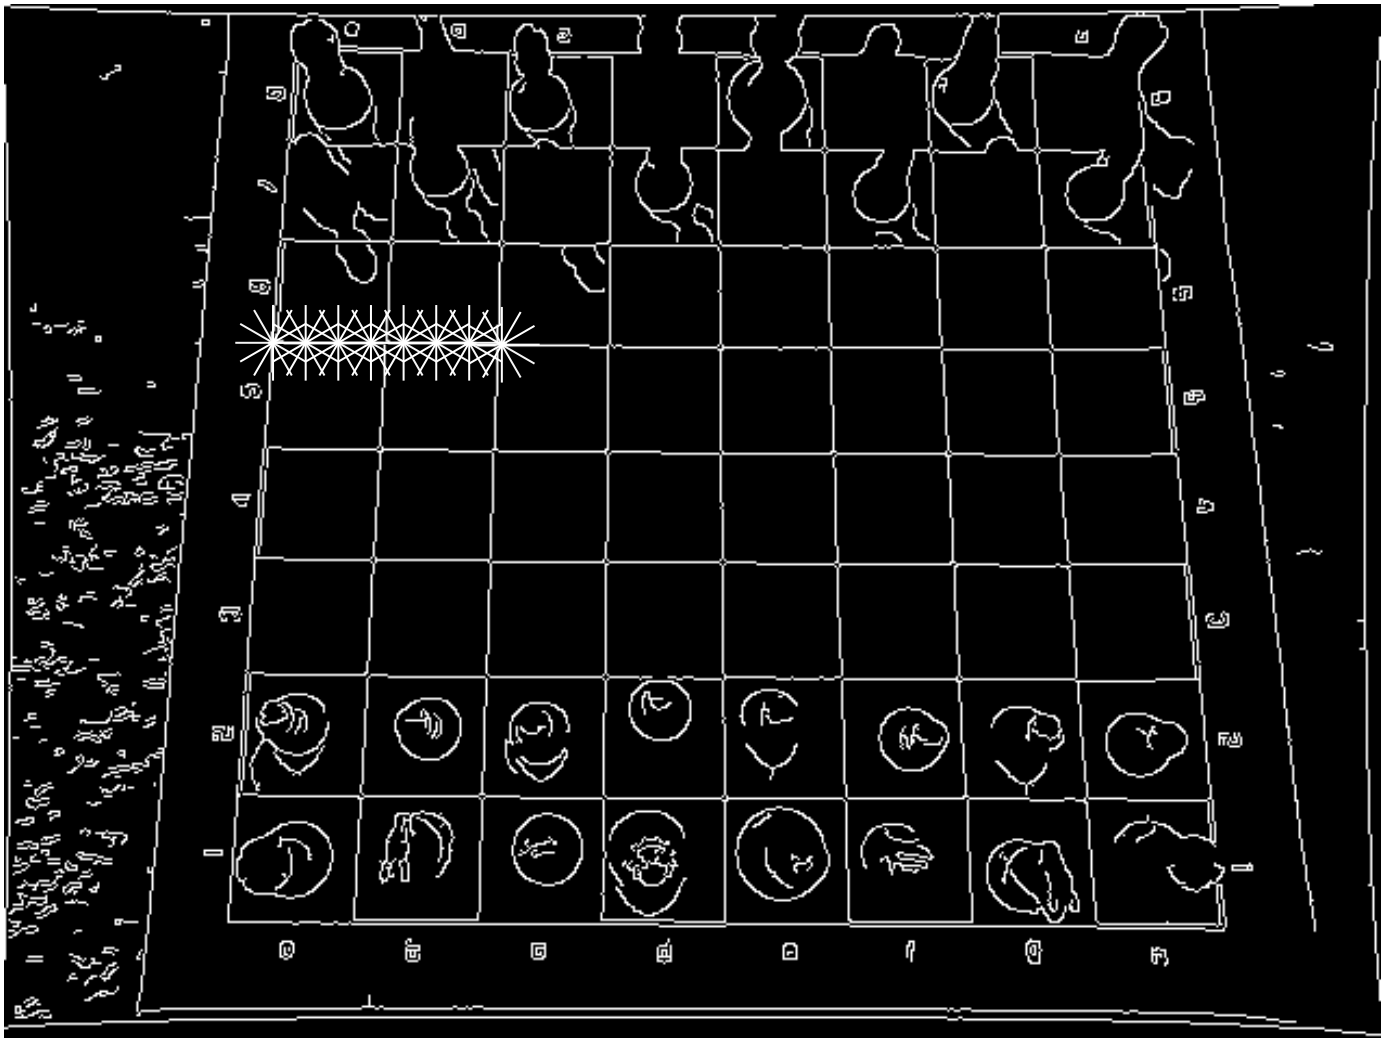
- Al termine della scansione i massimi dell'array A denotano le rette candidate presenti sull'immagine.

- Nella pratica per la localizzazione di rette con trasformata di Hough si preferisce la parametrizzazione in coordinate polari:

$$\rho = x \cdot \cos\theta + y \cdot \sin\theta$$

in quanto la discretizzazione dei parametri (m, c) comporta problemi per rette verticali o quasi verticali. In questo caso durante il ciclo interno si calcola il valore di ρ per diversi valori discreti di θ.

Esempio pratico



Trasformata di Hough: *rette* (3)



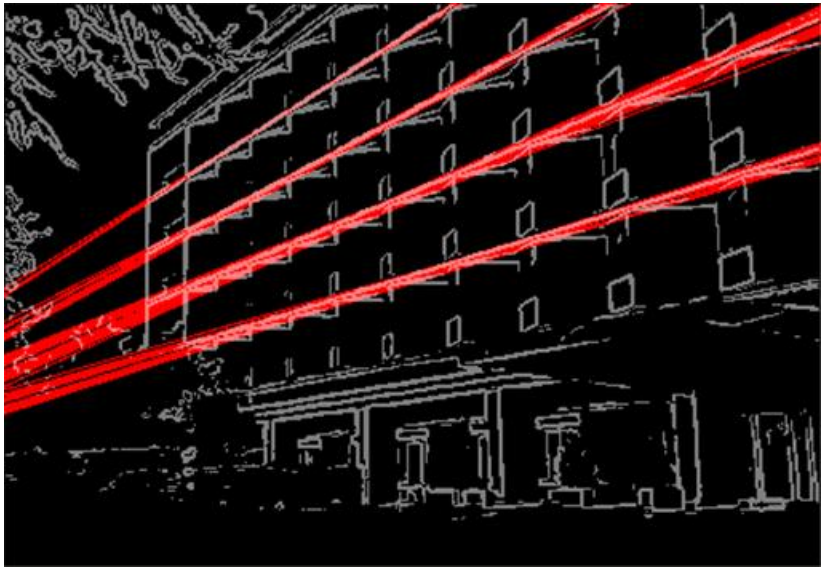
Gradiente (Sobel)



Binarizzazione (Soglia Globale)



Le 30 rette più probabili localizzate con trasf. Hough



Trasformata di Hough: *circonferenze (1)*

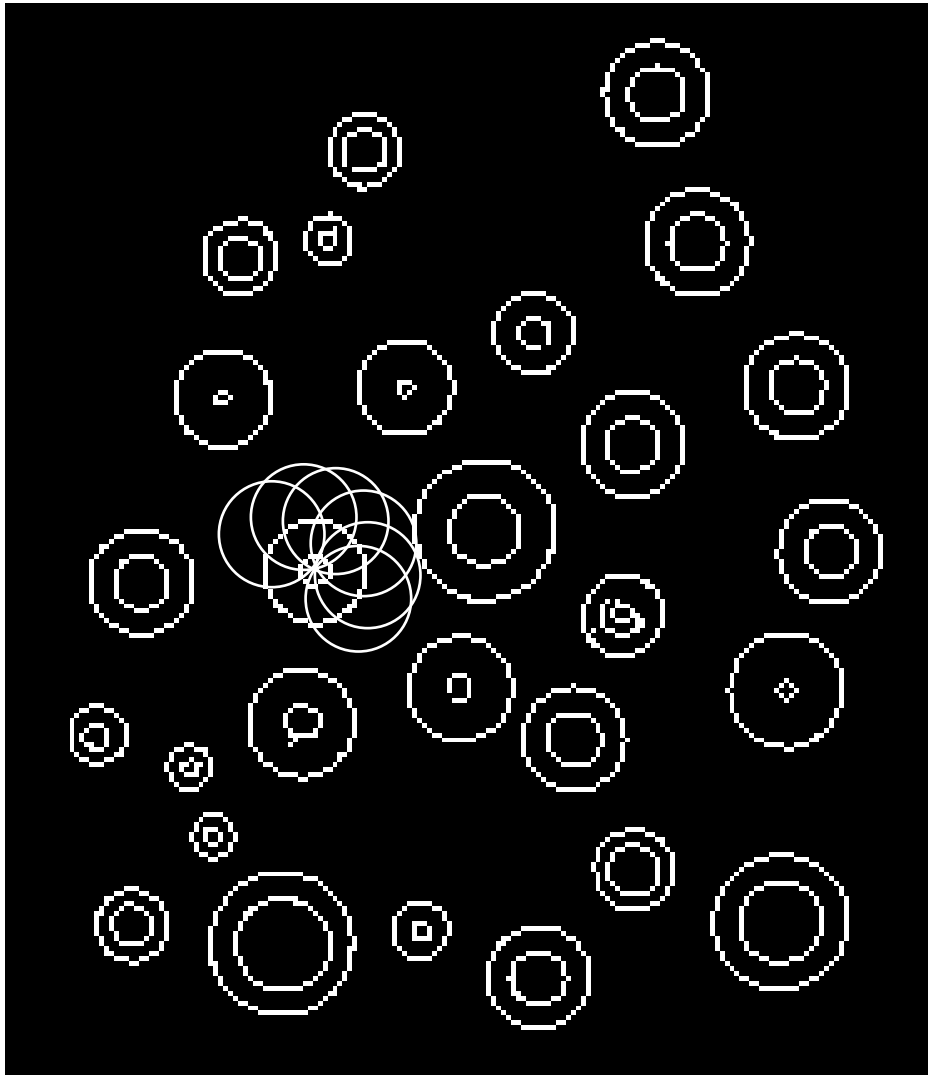
- Ogni circonferenza nel piano xy può essere descritta dall'equazione:

$$r^2 = (\mathrm{x} - x_c)^2 + (\mathrm{y} - y_c)^2$$

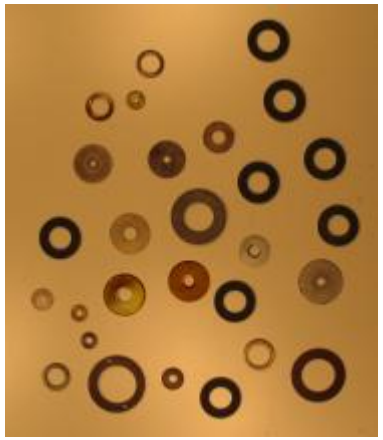
- La trasformata può essere impiegata per localizzare circonferenze di *raggio prefissato*: in questo caso r è costante e l'array degli accumulatori è bidimensionale: $\mathbf{A}[x_{c1}\ x_{c2} \ldots\ x_{cr}][y_{c1}\ y_{c2} \ldots\ y_{cs}]$

- Se invece si desiderano tutte le circonferenze il cui raggio ricade entro un range prefissato, lo spazio dei parametri (x_c, y_c, r) viene discretizzato e codificato da un array tridimensionale $\mathbf{A}[x_{c1}\ x_{c2} \ldots\ x_{cr}][y_{c1}\ y_{c2} \ldots\ y_{cs}][r_1\ r_2 \ldots\ r_t]$. In questo caso la complessità computazionale è ovviamente superiore.

Esempio pratico

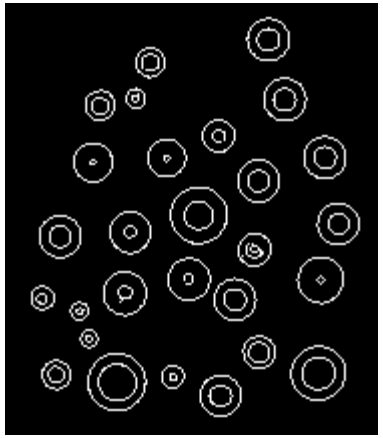


Trasformata di Hough: *circonferenze (2)*



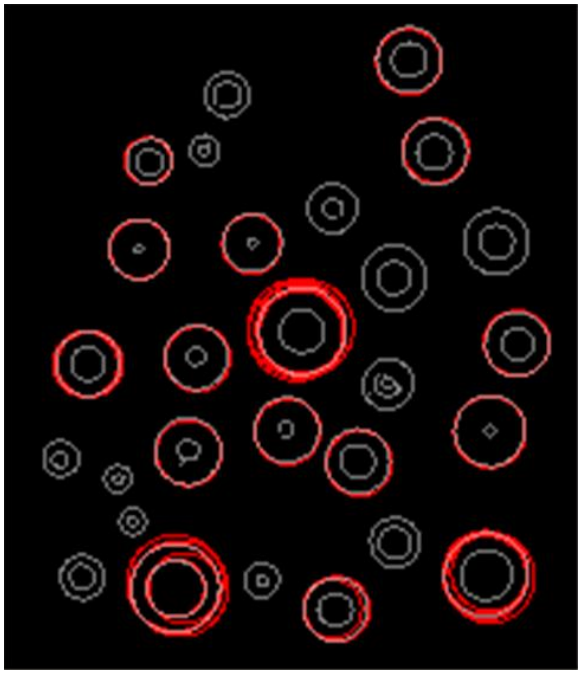


Bordi (Canny)
e binarizzazione





Le 30 circonferenze
più probabili



Trasformata di Hough: *ellissi*

- Nell'approccio base è sufficiente sostituire l'equazione dell'ellisse a quella del cerchio:

$$\left(\frac{\mathrm{x}-x_c}{a}\right)^2+\left(\frac{\mathrm{y}-y_c}{b}\right)^2=1$$

- Da notare però che i parametri sono in questo caso 4 e per ottenere implementazioni efficienti è necessario adottare semplificazioni.

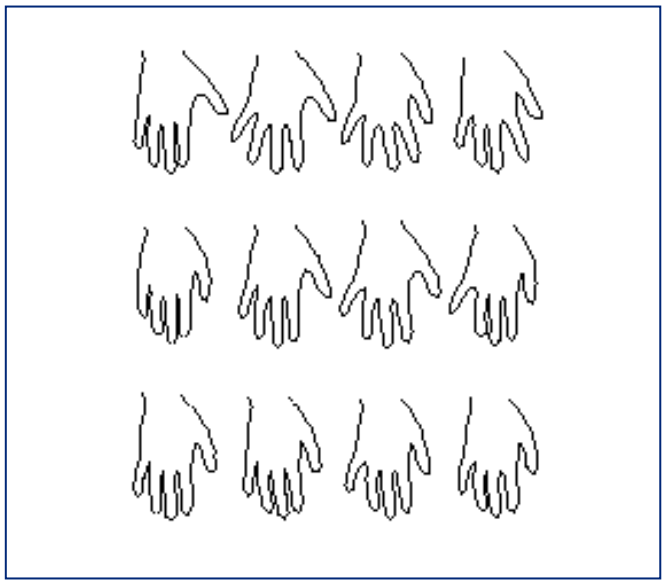
Template matching deformabile

Shape learning (1)

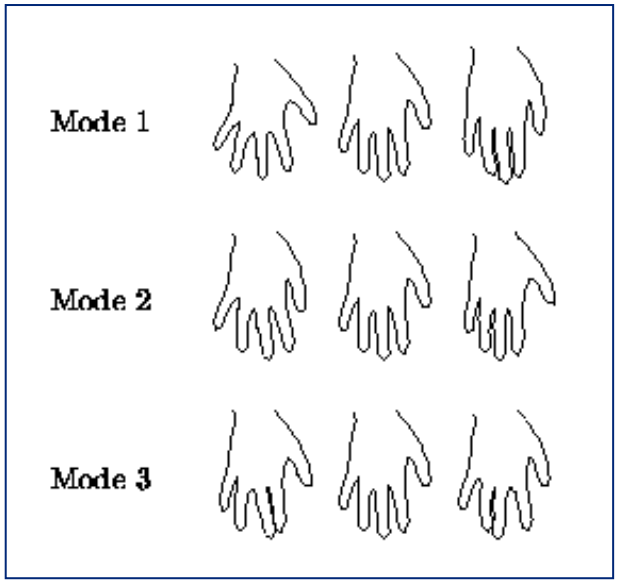
- ***Shape learning (Apprendimento della forma da esempi)***: spesso risulta complicato fornire espressioni analitiche di un template e altrettanto difficile definire precisamente le trasformazioni che mappano un oggetto nelle sue possibili deformazioni.
- I metodi di **Shape learning** hanno come obiettivo l'apprendimento della forma di un oggetto e delle sue possibili variazioni a partire da un insieme di esempi.
- Nel metodo di Cootes il template viene modellato da poligonali; durante l'addestramento gli esempi nel training set sono allineati (manualmente) sulla base di punti notevoli. I molteplici gradi di libertà dati dalla mobilità spaziale di punti corrispondenti nei diversi pattern di esempio vengono fortemente ridotti (trasformata KL) per ottenere un modello parametrico con pochi gradi di libertà.

T. Cootes e C. Taylor, "Statistical Models of Appearance for Computer Vision", Internal report Manchester University, Dec.2000.

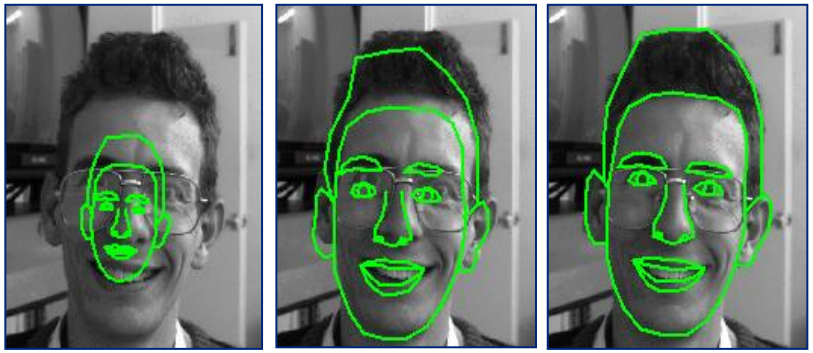
Shape learning (2)



Training set (a sinistra)
e modello parametrico appreso (a destra)

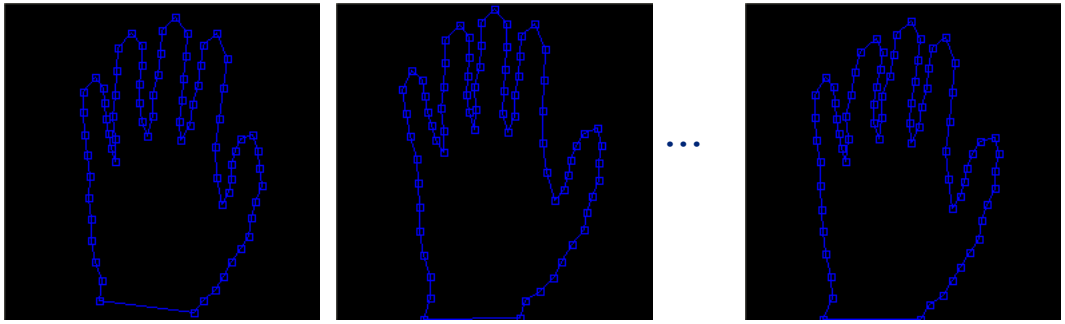


Convergenza del modello a partire da una soluzione iniziale “molto imprecisa”



Esempi (1)

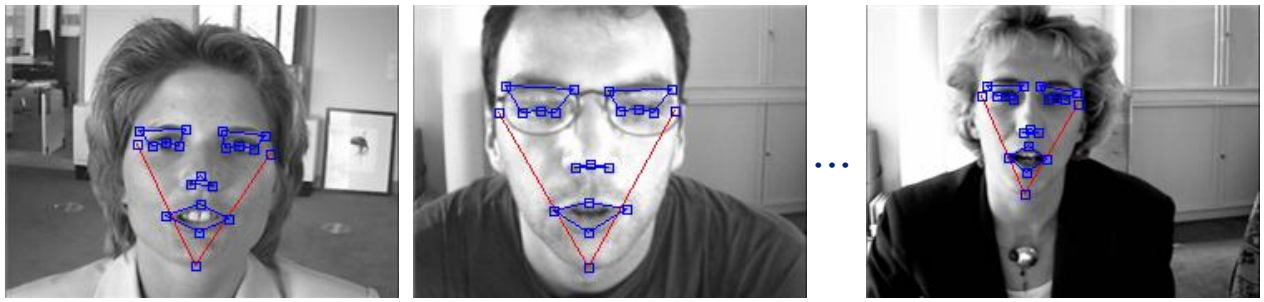
- ***Forma della Mano***: 18 immagini di mani etichettate con una poligonale facendo attenzione a marcare i punti “corrispondenti” sempre nello stesso ordine.



I 5 “modi di variazione principale” determinati con KL transform gestiscono molto bene buona parte delle possibili variazioni.

Esempi (2)

- ***Caratteristiche interne del volto***: 200 immagini di volti etichettate con più poligonali facendo attenzione a marcare i punti "corrispondenti" sempre nello stesso ordine.



anche in questo caso i 5 "modi di variazione principale" determinati con KL transform gestiscono molto bene buona parte delle possibili variazioni.